

大数据管理与应用专业

大数据综合项目实训报告

报告题目： 《基于美团数据不同出场景下用户
全链路动线和需求洞察》

学生姓名： 杨玥萌 高琪 史俊杰 益西措姆

学生学号： 2023211015 2023215475 2023210847
2023210863

所在班级： 大数据 23-1 班

指导老师： 李兰兰

完成时间： 2026. 7. 5

摘要

随着本地生活服务平台的业态边界不断拓展,用户在出行场景下的消费需求呈现明显的链式特征——酒店住宿往往伴随餐饮、外卖、闪购等衍生需求。然而,目前的补贴策略割裂于各业务线,难以实现跨业态的协同增长。本研究基于美团用户画像表(200 条)与交易订单表(约 1000 条),围绕“识别→预测→推荐”构建完整分析链路。在数据预处理阶段,通过 user_id 关联两表,提取订单聚合特征与画像衍生特征,构造商旅、情侣、亲子、特种兵四类出行场景标签,输出用户级宽表。在模型构建阶段,采用 XGBoost 多分类模型识别用户出行场景,准确率达 98%;采用随机森林与 XGBoost 二分类模型预测用户对外卖、到餐、闪购的需求概率,AUC 均达到 0.6 以上。在策略设计阶段,基于 Apriori 关联规则挖掘,生成场景专属券包方案,形成从数据融合到智能推荐的完整闭环。研究结果表明,基于订单行为与画像特征融合的方法能够有效识别用户出行场景并预测其衍生需求,为平台跨业态精准营销提供了可落地的数据驱动方案。

关键词: 出行场景识别; 需求预测; XGBoost; 关联规则挖掘; 跨业态推荐

目录

1 绪论	7
1.1 研究背景与意义	7
1.2 国内外研究现状	8
1.2.1 国外研究现状	8
1.2.2 国内研究现状	9
1.3 研究内容	10
1.4 研究思路与技术路线	11
2 数据采集与预处理	13
2.1 数据来源与采集方法	13
2.1.1 数据源描述	13
2.1.2 数据规模说明	13
2.1.3 数据采集方法	13
2.2 数据存储	14
2.2.1 存储方式	14
2.2.2 数据结构设计	14
2.3 数据预处理	16
2.3.1 数据清洗	16
2.3.2 特征提取	17
2.3.3 场景标签构造	19
2.3.4 数据规约	20

2.3.5 输出数据质量评估	21
3 出行目的识别模型	22
3.1 问题描述	22
3.2 模型选择	22
3.2.1 核心模型选择依据	22
3.2.2 模型原理简述	23
3.3 实验设计	23
3.3.1 数据集划分	23
3.3.2 交叉验证策略	24
3.3.3 评估指标	24
3.3.4 超参数设置	24
3.4 结果与讨论	25
3.4.1 监督学习模型性能对比	25
3.4.2 特征重要性分析	26
3.4.3 无监督学习验证结果	27
3.4.4 业务价值与策略启示	29
4 全链路需求预测模型	31
4.1 问题描述	31
4.2 模型选择	32
4.3 模型评估	33
4.4 结果与讨论	33
4.4.1 模型性能对比	33

4.4.2 特征重要性分析	34
4.4.3 数据局限性说明	38
5 跨业态神券包设计	39
5.1 关联规则挖掘方法与指标体系	39
5.1.1 问题描述	39
5.1.2 关联规则挖掘	39
5.1.3 阈值设定依据与参数校准	40
5.2 品类关联规则结果分析	41
5.3 各场景品类消费渗透率分析	43
5.3.1 渗透率定义	43
5.3.2 渗透率结果分析	43
5.4 跨业态动态神券包方案设计	45
5.4.1 方案设计思路	45
5.4.2 最终方案推荐	45
5.4.3 方案应用价值	46
5.5 结果可视化	46
5.6 结果分析与业务讨论	48
5.6.1 关联规则结果解读	49
5.6.2 策略业务可行性分析	49
5.6.3 策略局限性分析	49
6 总结与展望	50
6.1 研究总结	50

6.2 业务价值讨论	51
6.3 研究展望	52
7 分工协作说明	55
7.1 项目执行阶段	55
7.2 报告撰写阶段	56

1 绪论

1.1 研究背景与意义

出行是美团生态中典型的“长链路、高价值”场景，涵盖了“规（规划）、订（预订）、游（在途/体验）、结（离店/评价）”四个关键阶段。与本地日常消费不同，异地出行用户的需求具有极强的时空关联性和业态发散性：一个预订了亲子房的用户，极有可能伴随着购买儿童乐园门票、点外卖（奶粉/急用药）或搜索周边特色餐厅的需求。

然而，目前的补贴策略往往割裂在各个独立的业务线（BU）中，各业态间的数据孤岛问题日益凸显，单一业态营销活动难以充分挖掘用户全链路消费价值^[1]。如何打破数据孤岛，以“出行”为串联线索，实现跨行业的动态组合策略，是平台级组织面临的核心课题^[2]。

从数据底座的角度看，用户的行为数据分散存储于不同的数据系统——画像数据记录用户的基础属性与长期消费特征，订单数据记录用户的交易行为与消费偏好。如何将订单粒度的交易数据聚合为用户粒度的行为特征，并与画像特征进行融合，是数据预处理的核心任务^[3]。特征工程的质量直接决定了上游模型的天花板^[4]。

从业务价值来看，出行场景识别与需求预测能够为平台带来三重增益：第一，精准营销层面，通过预判用户场景，可在入住前推送个性化神券包，提升券包核销率与交叉销售转化率^[5]；第二，资源优化层面，帮助平台提前调配运力与库存，降低履约成本^[6]；第三，用户体验层面，减少无效信息干扰，实现“千人千面”的服务触达^[7]。

因此，本研究围绕三个分析目标展开：（1）出行目的与人群画像解码——精准识别商旅、亲子、情侣、特种兵等出行人群类型；（2）全链路需求预测与时机捕捉——预测用户在“规-订-游-结”不同阶段的连带需求；（3）跨业态动态组合策略设计——构建“酒店+X”的场景化推荐模型，动态生成跨品类的神券包。构建从数据融合到场景识别、需求预测直至策略推荐的完整分析链路，具有重要的理论研究价值与工程实践意义^{[8][9]}。

1.2 国内外研究现状

1.2.1 国外研究现状

在用户画像与场景识别方面，Chen 和 Guestrin^[10]于 2016 年提出的 XGBoost 算法因其高效处理稀疏数据、支持并行计算与内置正则化等特性，已成为用户分群与多分类任务的主流工具，广泛应用于电商客户细分、金融风控等领域。Ni 和 Duan^[11]提出了基于改进 XGBoost 模型的电子商务客户智能分类方法，通过优化梯度提升树的参数配置与特征权重分配，显著提升了大规模电商用户分类的精度与鲁棒性。在异常用户识别方面，Xie^[12]提出基于多特征的社会网络异常用户精确识别方法，利用 XGBoost 构建目标函数，识别准确率超过 95%。Breiman^[13]提出的随机森林算法因其天然具备特征重要性评估能力，已成为特征选择环节的常用工具。Guyon 和 Elisseeff^[4]在其特征选择综述中系统比较了过滤法、包裹法与嵌入法三类特征选择方法的优劣，指出特征选择的目标在于提升预测性能、提供更快更经济的预测器以及更好地理解底层领域。

在聚类分析与客户细分方面，Zhao 等^[14]提出了一种扩展正则化 K- Means 聚类方法，用于处理高维客户细分中的相关变量问题，通过引入正则化项改善了聚类质量。Calinski 和 Harabasz^[15]提出的 CH 指数与 Rousseeuw^[16]提出的轮廓系数等聚类评估指标被广泛应用于无监督场景分群，以验证聚类结果与业务标签的一致性。Gomes 和 Meisen^[2]在对 105 篇文献的系统综述中发现，K- Means 聚类是最常用且最适合的客户细分技术，而随机森林和人工神经网络在监督学习任务中表现优异。

在需求预测方面，Latief 和 Bhat^[17]提出了基于注意力驱动图神经网络的食品配送时空需求预测方法，利用图神经网络捕捉需求的空间依赖关系。Zhao 等^[18]提出了 STKDRec 模型，通过两阶段训练过程——第一阶段预训练时空知识图谱编码器，第二阶段采用时空 Transformer 建模用户动态偏好，并引入知识蒸馏策略融合时空知识。Deng 等^[19]提出了基于异构时序建模和大语言模型的外卖系统上下文驱动推荐方法。

在关联规则挖掘方面，Agrawal 和 Srikant^[20]于 1994 年正式提出 Apriori 算法，通过逐层迭代的频繁项集挖掘框架奠定了关联规则挖掘的理论基础。Guo^[21]

针对移动电商场景改进了 Apriori 算法并构建了实时商品推荐系统，验证了关联规则在个性化推荐中的有效性。Chen 和 Gunawan^[22]提出了基于改进 RFM 分析与关联规则挖掘的数据驱动推荐方法，通过将 RFM 客户细分与 Apriori 关联规则相结合，实现了零售交易场景下的精准商品推荐。

总体而言，国外研究在算法性能优化与特征工程方法论方面提供了坚实的理论基础，但针对出行场景下“酒店+本地生活”跨业态融合的专项研究仍较为有限。

1.2.2 国内研究现状

国内学者在用户画像构建与交易数据分析方面也取得了丰富成果。

在客户细分领域，基于 K-means 聚类算法的客户细分研究已较为成熟。郭允涛和白钊^[23]在传统 K-means 聚类算法的基础上改进 RFM 模型，引入轮廓系数改进 K-means 聚类算法，应用于航空客户细分场景，研究表明与肘部法相比，利用轮廓系数选择 K 值更加直观有效，能提高客户细分的准确性。有学者基于 RFM 模型和 K-means、DBSCAN、AGNES、GMM 等四种聚类算法对零售市场客户细分进行了系统对比研究^[24]。王丽娟等^[25]提出了改进的 K-means 算法，使用改进的轮廓系数公式判断初始聚类数目，并利用欧式距离相似度与余弦相似度的测度优势提出离群点过滤规则，应用于寿险客户流失预测，实证表明改进算法可降低可视化噪声、减小簇内误差方差。

在出行目的识别方面，陆振波等^[26]提出了一种基于手机信令数据的出行目的识别方法，利用 ST-DBSCAN 密度聚类算法识别出行停留点，将出行链划分为多个出行段，并基于贝叶斯网络模型实现出行目的的精准推断。该方法充分利用了手机信令数据的全样本特性，克服了传统居民出行调查样本量低、成本高的缺陷。胡宝雨和刘学^[27]基于手机信令数据探索城市区域居民出行目的地选择机制，考虑人口数量和 POI 数量两类数据建立地点机会选择模型，从交通小区和交通中区两个尺度对居民出行 OD 进行预测。Vlahogianni 等^[28]基于智能手机众感数据，设计了一种结合 DBSCAN 聚类与规则建模的混合方法，用于检测用户的主要活动并构建出行链，证明了行为序列特征在出行语义挖掘中的核心作用。

在需求预测方面，丁翔、倪丽萍和韩露^[29]提出了一种基于深度学习的即时配送时间预测模型，考虑不同因素对配送过程的影响，使用地理哈希、图嵌入等方

法对多种特征进行表示, 并采用多头自注意力模型进行预测。王梦晓^[6]基于外卖数据进行了热点区域挖掘及订单量预测研究, 采用自适应深度神经网络构建订单量预测模型。肖云和刘洋等^[30]提出了基于改进 K 近邻算法的城市配送需求量预测方法。

在关联规则与推荐系统方面, 史达、于淼川和李梦琪^[31]在基于物品协同过滤的基础上, 对隐式反馈数据进行挖掘建模, 设计了隐式反馈偏好评分规则, 并引入 XGBoost 模型对推荐结果进行过滤, 实现了个性化酒店推荐。林穗等^[32]对 Apriori 算法进行改进, 引入权值参数区分不同用户与行为的重要性, 实现了电商商品的个性化推荐。王君威等^[33]将 Apriori 挖掘得到的商品强关联规则融入协同过滤框架, 有效缓解了数据稀疏带来的推荐偏差。朱龙^[34]提出了带商品利润权重的 Apriori 改进算法, 能够挖掘利润导向的商品关联规则。孙一凡等^[35]针对零售场景优化了 Apriori 算法, 构建了最优促销产品组合方案。刘巧等^[36]结合 RFM 聚类与关联规则算法, 对社交电商用户的购买行为进行分层挖掘, 为差异化营销提供了完整的分析框架。

综上所述, 国内研究多聚焦于通用电商、交通出行等场景, 针对出行场景下“酒店+X”跨业态权益组合策略的研究相对较少, 本研究能够对该领域形成有效补充。

1.3 研究内容

本研究以美团用户画像表与交易订单表为数据源, 构建从数据融合到策略推荐的完整分析链路, 具体研究内容包括以下四个方面:

(1) 数据预处理与特征工程。基于用户画像表(200 条)与交易订单表(约 1000 条), 通过 user_id 进行一对一关联, 提取订单维度的聚合特征(总订单数、总消费金额、外卖/到餐/闪购订单数、夜间订单数、平均客单价)与画像衍生特征(年龄分组、会员等级数值化、客单价分层数值化)。在数据预处理方法论方面, 学者们从定义、任务、内容、方法、算法等多角度对数据预处理技术进行了全方位的探讨, 论述了数据预处理在数据挖掘中的重要地位^{[3][4]}。基于订单行为与画像特征的组合, 构造商旅、情侣、亲子、特种兵四类出行场景标签, 输出用户级宽表供后续建模使用。

(2) 出行目的识别模型。以 XGBoost 与随机森林为核心模型，以逻辑回归与决策树为基线模型，开展多分类任务^{[10][13]}。输入特征涵盖用户画像、历史订单与消费行为等维度，输出四类场景标签。同时采用 K- Means 聚类进行无监督验证，检验用户行为特征在无标签条件下的自然分群能力^{[14][16]}。针对亲子样本仅 1 个的极端不平衡问题，采用合并策略（亲子并入情侣），形成商旅、情侣、特种兵三分类任务。

(3) 全链路需求预测模型。分别针对外卖、到餐、闪购三个二分类预测任务，采用逻辑回归、随机森林、XGBoost 三种模型进行训练和对比。以 AUC 为主要评估指标，识别对各类需求预测贡献最大的特征，并对全部用户输出三类需求的发生概率^{[17][19]}。

(4) 跨业态组合策略设计。采用 Apriori 关联规则挖掘算法，对用户场景标签与跨品类消费数据进行联合挖掘，以支持度、置信度、提升度作为核心评价指标，识别不同出行场景下的差异化消费偏好与品类关联规律^{[20][22]}。基于挖掘结果设计场景专属券包方案，并通过热力图、雷达图等可视化形式对策略结果进行呈现^{[32][35]}。

1.4 研究思路与技术路线

本研究的技术路线如图 1.1 所示，整体分为四个阶段：

第一阶段：数据预处理与特征工程。从神券订单数据样例(1).xlsx 中读取用户画像表（200 条）与交易订单表（约 1000 条），进行数据清洗与缺失值处理。对订单表按 user_id 进行聚合，提取 7 个订单维度特征；对画像表进行年龄分段、会员等级数值化、客单价分层数值化等衍生处理。将画像特征与订单特征通过 user_id 进行一对一融合，构造商旅、情侣、亲子、特种兵四类场景标签，输出清洗后的用户宽表 cleaned_data.csv（200 个用户×18 列特征），供后续建模使用。

第二阶段：出行目的识别模型。接收清洗后的宽表，对年龄分组进行 LabelEncoder 编码，对常驻城市进行频率编码，构建标准化特征矩阵。针对亲子样本仅 1 个的极端不平衡问题，采用合并策略（亲子并入情侣），形成商旅、情侣、特种兵三分类任务。监督学习部分采用 LogisticRegression、DecisionTree、RandomForest、XGBoost 四种模型进行对比，通过 5 折分层交叉验证选择最优模型；无监督学习部分采用 K-Means（K=4）进行聚类，利用轮廓系数等指标评估

聚类质量^{[15][16]}。输出每个用户的场景预测标签及概率分布、特征重要性排序，供后续模块使用。

第三阶段：全链路需求预测模型。 基于第一阶段输出的用户宽表，提取用户画像特征（会员等级、客单价分层、年龄分组、常驻城市、场景标签）与行为特征（点击次数、搜索次数、浏览次数等），排除与目标变量直接相关的订单统计特征以避免数据泄露。分别针对外卖、到餐、闪购三个二分类预测任务，采用逻辑回归、随机森林、XGBoost 三种模型进行训练与对比，以 AUC 为主要评估指标^[17]。输出每个用户对三类需求的发生概率及特征重要性排序。

第四阶段：跨业态组合策略设计。 基于第二阶段输出的场景标签与第三阶段输出的需求概率，采用 Apriori 关联规则挖掘算法^[20]，对用户场景标签与品类消费数据进行联合挖掘，以支持度、置信度、提升度为核心评价指标识别强关联规则。基于挖掘结果构建“提升度优先+渗透率兜底+场景特色补充”的三层筛选逻辑，生成差异化的场景专属券包方案（商旅用户：咖啡券+单车券；亲子用户：乐园门票+母婴券；情侣用户：黑珍珠餐厅券+电影票；特种兵用户：奶茶券+充电宝券）。最终通过热力图、雷达图等可视化形式对策略结果进行呈现^{[32][35]}，形成完整的“识别—预测—推荐”闭环。




图 1.1 总体技术路线图

2 数据采集与预处理

2.1 数据来源与采集方法

2.1.1 数据源描述

本研究的数据来源于美团平台 2026 年 1 月 11 日的用户画像与订单数据，经过脱敏处理后提供。数据文件为神券订单数据样例(1).xlsx，包含两张数据表：

表 2.1 数据源概览

数据表	记录数	关键字段	user_id 格式
用户画像表	200 条	user_id、常驻城市、年龄、用户生命周期阶段、会员状态、历史实付分层	USER000001~USER000200
交易订单表	约 1000 条	order_id、下单时间、bu_name、user_id、POI 分类、订单金额	USER000001~USER000200

2.1.2 数据规模说明

用户画像表覆盖 200 个独立用户，包含年龄、常驻城市、会员状态、历史客单价分层等基础画像信息。交易订单表记录约 1000 笔有效订单（过滤金额≤0 后），覆盖 197 个有消费行为的用户，3 个用户无任何订单记录。订单涵盖外卖、到餐、闪购三个主要业务线（以实际数据为准），POI 分类覆盖饮品、快餐简餐、火锅、超市便利、水果、食材等 20 余个品类。

表 2.2 订单业务线分布统计

业务线	订单数	占比
外卖	500	0.6250
到餐	150	0.1875
闪购	150	0.1875
合计	约 800	100%

2.1.3 数据采集方法

数据采集采用 Python 的 pandas 库直接读取 Excel 文件的方式：

```
print("\n 读取用户画像表...")

user_profile = pd.read_excel('神券订单数据样例(1).xlsx', sheet_name='用户画像表')

user_profile['user_id'] = user_profile['user_id'].astype(str)

print(f'画像表形状: {user_profile.shape}')
```

通过网络爬虫或 API 接口进行采集。数据的读取与处理均在本地完成，符合数据安全和合规要求。

2.2 数据存储

2.2.1 存储方式

清洗后的宽表以 CSV 格式存储，采用 UTF-8 编码，字段间以逗号分隔。CSV 格式具有轻量、通用、可读性强、与 Python/R/Excel 等工具兼容性好等优点，便于后续建模环节读取与使用。

2.2.2 数据结构设计

最终输出的宽表 cleaned_data.csv 包含 18 个字段，可分为六组：

（1）用户标识字段

user_id：用户唯一标识，字符串类型，格式为 USER000001~USER000200。

（2）场景标签字段

scene_label：出行场景标签，字符串类型，取值为商旅、情侣、亲子、特种兵四类。

（3）需求意愿特征（目标变量）

will_order_waimai：是否会点外卖，整型，0/1 二分类标签。

will_order_daocan：是否会到餐，整型，0/1 二分类标签。

will_order_shangou：是否会闪购，整型，0/1 二分类标签。

will_order_ticket：是否会购票，整型，恒为 0（数据中无门票订单）。

（4）用户画像特征

age_group：年龄分组，分类型，取值为青年、中年、中老年。

member_level_num：会员等级数值，整型，取值范围 1~6（L1→1 ... L6→6）。

price_level_num: 客单价分层数值, 整型, 取值范围 1~4 (低→1 ... 超高→4)。
常驻城市: 用户常驻城市, 字符串类型。

(5) 历史订单特征 (从订单表聚合)

total_orders: 总订单数, 浮点型。
total_amount: 总消费金额, 浮点型。
waimai_orders: 外卖订单数, 浮点型。
daocan_orders: 到餐订单数, 浮点型。
shangou_orders: 闪购订单数, 浮点型。
night_orders: 夜间订单数, 浮点型。
avg_amount: 平均客单价, 浮点型。

(6) 亲子特征

parenting_orders: 亲子订单数, 浮点型, 基于 POI 分类识别 (母婴玩具/儿童乐园/亲子/孕产/玩具/童装/早教)。

表 2.3 数据宽表字段说明

字段名	数据类型	含义	取值范围
user_id	str	用户唯一标识	USER000001~USER000200
scene_label	str	出行场景标签	商旅/情侣/亲子/特种兵
will_order_waimai	int	是否会点外卖	0 或 1
will_order_daocan	int	是否会到餐	0 或 1
will_order_shangou	int	是否会闪购	0 或 1
will_order_ticket	int	是否会购票	恒为 0
age_group	category	年龄分组	青年/中年/中老年
member_level_num	int	会员等级数值	1~6
price_level_num	int	客单价分层数值	1~4
常驻城市	str	常驻城市	城市名称
total_orders	float	总订单数	≥0

字段名	数据类型	含义	取值范围
total_amount	float	总消费金额（元）	≥ 0
waimai_orders	float	外卖订单数	≥ 0
daocan_orders	float	到餐订单数	≥ 0
shangou_orders	float	闪购订单数	≥ 0
night_orders	float	夜间订单数	≥ 0
avg_amount	float	平均客单价（元）	≥ 0
parenting_orders	float	亲子订单数	≥ 0

2.3 数据预处理

2.3.1 数据清洗

（1）缺失值处理。检查用户画像表，所有 200 个用户的画像信息（年龄、常驻城市、会员状态、历史客单价分层）均完整，无缺失值。交易订单表中，存在部分记录的“订单金额”字段为 NULL 或无值，在后续分析中予以保留。对于个别订单金额为 NULL 的记录，已填充为 0 并过滤，确保聚合计算不受影响。

（2）异常值检测与处理。对订单金额字段进行异常值检测。经排查，不存在订单金额 ≤ 0 的异常记录，所有正数订单均保留。时间戳字段格式统一为 HH:MM:SS，无异常格式。

（3）重复值处理。检查交易订单表的 order_id 字段，确认无重复订单记录（注意：原始数据中存在两个 0000091 订单号，经核实为两个不同用户的独立订单，系数据编码问题，不影响分析）。

表 2.4 数据清洗前后对比

检查项	清洗前	清洗后	处理方式
画像表记录数	200	200	无缺失
订单表记录数	约 1000	约 1000	过滤金额 ≤ 0
订单金额缺失	少量	0	填充 0 后过滤

检查项	清洗前	清洗后	处理方式
重复订单号	2 个（不同用户）	2 个	保留（不同用户）

2.3.2 特征提取

（1）**订单聚合特征**。以 user_id 为分组键，从交易订单表中提取 8 个订单维度的聚合特征：

表 2.5 订单聚合特征说明

特征	计算公式	业务含义
总订单数	count(order_id)	用户消费频次
总消费金额	sum(订单金额)	用户消费能力
外卖订单数	count(bu_name == '外卖')	外卖需求强度
到餐订单数	count(bu_name == '到餐')	堂食需求强度
闪购订单数	count(bu_name == '闪购')	即时零售需求强度
夜间订单数	count(hour between 21 and 3)	夜间消费偏好
平均客单价	mean(订单金额)	消费档次
亲子订单数	count(is_parenting == True)	亲子消费需求

（2）**画像衍生特征**。从用户画像表中提取 4 个核心画像字段，并对其中的分类变量进行编码转换：

年龄分组：将连续年龄按业务规则分段。分段标准为：18 岁及以下为“青少年”、19-30 岁为“青年”、31-45 岁为“中年”、46 岁及以上为“中老年”。本数据集集中主要为青年与中年用户。




图 2.1 用户年龄分布图

会员等级数值化：将 L1~L6 的会员等级映射为 1~6 的数值，以便后续模型使用。




图 2.2 会员等级分布图

客单价分层数值化：将低客单价、中客单价、高客单价、超高客单价映射为 1~4 的数值。

常驻城市：直接保留原始城市名称，用于后续分群分析。




图 2.3 用户常驻城市分布图

2.3.3 场景标签构造

基于订单行为与画像特征的组合，本研究通过业务规则构造出行场景标签。规则设计参考了赛题业务背景中“商旅用户追求效率与咖啡/快餐”、“情侣用户关注氛围感餐厅”、“亲子用户关注儿童乐园与母婴用品”、“特种兵用户追求高性价比”的场景定义。

(1) 亲子标签规则。亲子用户的典型特征是家庭出行场景下的亲子消费。定义为：有亲子相关订单（`parenting_orders > 0`），其中亲子相关订单通过 POI 分类识别（母婴玩具、儿童乐园、亲子、孕产、玩具、童装、早教）。共命中 1 人（USER000011）。

(2) 情侣标签规则。情侣用户的典型特征是双人/多人用餐场景下的高消费与堂食偏好。定义为：有到餐订单（`daocan_orders > 0`）且平均客单价>50 元。共命中 49 人。

(3) 商旅标签规则。商旅用户的典型特征是出差场景下的效率优先——高频外卖消费与较高的会员等级/消费能力。定义为：有外卖订单（`waimai_orders > 0`）且（会员等级 ≥ 4 或 客单价分层 ≥ 3 ）。共命中 60 人。

（4）**特种兵标签规则**。特种兵用户的典型特征是高频低价、多业态探索。定义为：不属于以上三类的其余用户。共命中 90 人。

表 2.6 场景标签构造规则与样本分布

场景标签	判定规则	样本量	占比
亲子	有亲子相关订单（POI 分类命中）	1	0.5%
情侣	有到餐订单 且 平均客单价>50 元	49	24.5%
商旅	有外卖订单 且（会员等级≥4 或 客单价分层≥3）	60	30%
特种兵	其余用户	90	45%
合计	-	200	100%

2.3.4 数据规约

原始画像表包含 6 个字段，订单表包含 10 个字段。经过特征提取与融合，输出宽表包含 18 个字段。数据规约的主要策略包括：

特征选择：保留与出行场景识别和需求预测直接相关的特征，剔除与业务目标无关的字段。

数据聚合：将订单粒度的数据聚合为用户粒度，大幅降低数据维度（从约 1000 行订单记录规约为 200 行用户记录）。

编码转换：将分类变量（年龄、会员等级、客单价分层）转换为数值型，便于机器学习模型处理。

表 2.7 数据规约前后对比

维度	规约前	规约后
数据表数量	2 张（画像表+订单表）	1 张（宽表）
记录数	画像表 200 条 + 订单表约 1000 条	200 条
字段数	画像表 6 字段 + 订单表 10 字段	18 字段
数据粒度	画像表（用户级）+ 订单表（订单级）	用户级

2.3.5 输出数据质量评估

清洗后的宽表经质量检查，确认以下指标：

表 2.8 数据质量评估结果

质量维度	评估结果
样本量	200 个用户，满足分类建模的基本需求
字段完整性	18 个字段全部有值，无缺失
订单覆盖率	197/200（98.5%）的用户有订单记录
标签平衡性	商旅 60 人，情侣 49 人，亲子 1 人，特种兵 90 人
城市覆盖率	200/200（100%）的用户有常驻城市信息
异常值比例	0%

最终输出的 cleaned_data.csv 已交付至成员 B（出行场景识别）、成员 C（需求预测）与成员 D（策略设计），供后续建模与分析使用。

	user_id	scene_lab	will_orde	will_orde	will_orde	age_group	member_le	price_level	常驻城市	总订单数	总消费金额	外卖订单数	到店订单数	网购订单数	夜间订单数	平均客单价	亲子订单数	特种兵订单数	总行为次数
1	USER00000	商旅	1	1	1	0 中年	4	4	北京	6	168.5	4	1	1	1	128.083333	0	0	0
2	USER00000	商旅	1	0	1	0 青年	5	3	上海	7	545.5	4	0	3	0	77.928571	0	0	0
3	USER00000	特种兵	1	0	0	0 中年	2	1	北京	3	122	2	0	0	0	40.666666	0	0	0
4	USER00000	特种兵	1	0	0	0 青年	2	1	广州	3	114.5	3	0	0	0	38.166666	0	0	0
5	USER00000	商旅	1	1	1	0 中年	4	4	深圳	7	211.5	3	1	1	1	30.214285	0	0	0
6	USER00000	情侣	1	1	1	0 青年	1	1	上海	3	279	1	1	1	1	93	0	0	0
7	USER00000	特种兵	1	1	1	0 中年	3	2	北京	3	140	1	1	1	1	46.666666	0	0	0
8	USER00000	情侣	1	1	1	0 青年	4	4	杭州	7	537	2	1	1	1	76.714285	0	0	0
9	USER00000	商旅	1	1	1	0 中年	6	4	上海	9	358.5	5	2	1	1	39.833333	0	0	0
10	USER00001	特种兵	1	0	0	0 青年	2	1	北京	3	56	1	0	0	0	18.666666	0	0	0
11	USER00001	亲子	1	1	0	0 中年	5	3	广州	7	243.5	4	2	0	0	34.785714	1	0	0
12	USER00001	商旅	1	1	1	0 青年	4	2	深圳	5	162	2	2	1	1	32.4	0	0	0
13	USER00001	情侣	1	1	1	0 中年	3	2	北京	7	429.5	4	1	1	1	61.357142	0	0	0
14	USER00001	特种兵	1	0	1	0 青年	1	1	上海	3	327	1	0	1	0	109	0	0	0
15	USER00001	特种兵	1	1	0	0 中年	2	1	广州	4	102	1	1	1	0	25.5	0	0	0
16	USER00001	商旅	1	0	0	0 中年	4	2	深圳	5	151.5	5	0	0	0	30.3	0	0	0
17	USER00001	商旅	1	1	1	0 中年	3	4	杭州	3	120.5	1	1	1	1	40.166666	0	0	0
18	USER00001	商旅	1	1	0	0 青年	4	2	成都	9	205.5	5	3	0	0	22.833333	0	0	0
19	USER00001	特种兵	1	0	0	0 中年	3	2	重庆	3	92	2	0	0	0	30.666666	0	0	0
20	USER00002	商旅	1	0	1	0 青年	4	2	武汉	7	269	4	0	3	1	38.428571	0	0	0
21	USER00002	特种兵	0	1	0	0 青年	2	1	南京	4	178	0	1	0	1	44.5	0	0	0
22	USER00002	情侣	1	1	1	0 中年	5	3	西安	9	873	5	1	2	1	97	0	0	0
23	USER00002	商旅	1	1	0	0 中年	4	2	苏州	8	284	6	1	0	1	35.5	0	0	0
24	USER00002	情侣	1	1	1	0 青年	3	2	天津	10	844	4	1	3	2	84.4	0	0	0
25	USER00002	情侣	1	1	0	0 中年	1	1	郑州	3	437.5	1	2	0	0	145.833333	0	0	0
26	USER00003	特种兵	0	1	1	0 青年	2	1	长沙	4	128.5	0	1	2	0	32.125	0	0	0
27	USER00002	情侣	1	1	1	0 中年	4	2	青岛	5	305.5	3	1	1	0	61.1	0	0	0
28	USER00002	商旅	1	0	1	0 中年	6	3	宁波	4	145.5	2	0	1	0	36.375	0	0	0
29	USER00002	商旅	1	1	0	0 中年	4	2	厦门	3	97	2	1	0	0	32.333333	0	0	0
30	USER00003	情侣	1	1	1	0 青年	3	2	福州	10	916	6	2	1	1	91.6	0	0	0
31	USER00003	商旅	1	1	1	0 中年	4	3	合肥	9	448.5	7	1	1	1	49.833333	0	0	0

图 2.4 最终输出宽表示例截图

3 出行目的识别模型

3.1 问题描述

出行目的识别本质上是一个多分类问题，其目标是通过用户的历史行为与画像特征，预测其当前出行所属的场景类别。在本项目中，场景标签由成员 A 基于业务规则构造，涵盖商旅、情侣、特种兵、亲子四类。

然而，在数据探索阶段发现，200 个样本中亲子场景仅 1 例（占比 0.5%），存在严重的类别不平衡问题。若直接进行四分类，不仅会导致模型对亲子类学习不足，还会因分层抽样时最小类样本不足而报错。因此，本研究将亲子合并至情侣（两者均具有家庭属性、高消费意愿与亲子/双人活动特征），最终形成**商旅、情侣、特种兵**三分类任务，样本分布分别为 60、50、90，比例约为 2:1.7:3，虽仍存在不均衡，但可通过 `class_weight='balanced'` 策略进行缓解。B

从特征维度看，输入特征共 22 个，可分为四类：需求意愿特征（4 个）：`will_order_waimai`、`will_order_daocan`、`will_order_shangou`、`will_order_ticket`，反映用户对各业态的预订倾向；用户画像特征（4 个）：`age_group_encoded`（年龄分组）、`member_level_num`（会员等级）、`price_level_num`（客单价分层）、`city_freq`（城市频率编码）；历史订单特征（8 个）：总订单数、总消费金额、外卖/到餐/团购/夜间订单数、平均客单价、亲子订单数；行为轨迹特征（6 个）：总行为次数、点击/搜索/加购/行为下单/收藏次数。

值得注意的是，行为轨迹特征（点击、搜索、加购等）在清洗后数据中全部为 0，说明在特征提取阶段可能未完整保留行为日志的细粒度信息，或该批次用户的行为数据存在缺失。这一局限性将在后续讨论中进一步分析。

3.2 模型选择

3.2.1 核心模型选择依据

本研究选择 XGBoost 与 RandomForest 作为核心模型，逻辑回归与决策树作为基线模型，其选择依据如下：

(1) XGBoost (极端梯度提升)。XGBoost 是基于梯度提升框架的优化实现，通过引入二阶泰勒展开、正则化项（L1/L2）与列采样策略，在计算效率与预测

精度上均优于传统 GBDT。Chen 和 Guestrin[10]在 KDD 2016 上的论文指出，XGBoost 在处理表格数据的多分类任务时，通常优于随机森林与单模型方法。本研究实际运行 XGBoost（`n_estimators=200`, `max_depth=5`, `learning_rate=0.1`），验证了其在该任务上的优越性：测试集 F1-Macro 达到 0.9811，交叉验证标准差仅为 0.0211，兼具高精度与稳定性。

（2）RandomForest（随机森林）。随机森林是一种基于 Bagging 思想的集成学习方法，通过构建多棵决策树并取平均投票结果，有效降低单棵决策树的过拟合风险。Gomes 和 Meisen[2]在对 105 篇文献的系统综述中指出，随机森林因其对高维特征的鲁棒性与可解释性，在电子商务客户细分任务中被广泛应用。其优势在于：第一，能够处理高维混合类型特征，无需进行复杂的特征缩放；第二，通过特征随机子集选择，天然具备特征重要性评估能力；第三，通过 `class_weight` 参数可灵活应对类别不平衡问题。

（3）基线模型。逻辑回归（LogisticRegression）作为线性基线，用于验证特征与标签之间是否存在显著的线性可分性；决策树（DecisionTree）作为非线性基线，用于检验单棵树的过拟合程度与集成学习的必要性。

3.2.2 模型原理简述

以 XGBoost 为例，其目标函数由损失函数与正则化项两部分组成：

$$\text{Obj} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

其中， $l(y_i, \hat{y}_i)$ 为损失函数（本研究采用多分类对数损失）， $\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ 为正则化项， T 为叶子节点数， w_j 为叶子权重。通过二阶泰勒展开近似损失函数，XGBoost 能够高效地找到最优分裂点，同时通过正则化防止过拟合。

3.3 实验设计

3.3.1 数据集划分

本研究采用分层随机划分策略，将 200 个样本按 8:2 比例划分为训练集（150 例）与测试集（50 例），并通过 `stratify` 参数确保训练集与测试集中各类别比例一致。具体划分结果如表 3.1 所示。

表 3.1 数据集划分与类别分布

数据集	样本量	商旅	情侣	特种兵	合计
训练集	150	45	37	68	150
测试集	50	15	13	22	50
合计	200	60	50	90	200

3.3.2 交叉验证策略

为降低随机划分带来的评估偏差，本研究在训练集上实施 5 折分层交叉验证（StratifiedKFold）。每一折中，训练集被进一步划分为 5 个子集，轮流取 4 个子集训练、1 个子集验证，最终取 5 次验证结果的均值与标准差作为模型泛化能力的评估依据。

3.3.3 评估指标

鉴于类别分布不均衡，本研究采用宏平均（Macro-average）指标，确保每个类别对最终评分的贡献相等。具体指标包括准确率、精确率、召回率、F1-score 及宏平均 F1（F1-Macro）。

3.3.4 超参数设置

各模型关键超参数如表 3.2 所示。

表 3.2 模型超参数设置

模型	关键超参数	说明
LogisticRegression	max_iter=2000, class_weight='balanced'	确保收敛并处理类别不平衡
DecisionTree	max_depth=5, class_weight='balanced'	限制树深度防止过拟合
RandomForest	n_estimators=200, max_depth=8, class_weight='balanced'	200 棵树的集成，适度深度限制
XGBoost	n_estimators=200, max_depth=5, learning_rate=0.1, subsample=0.8	梯度提升，正则化防止过拟合

3.4 结果与讨论

3.4.1 监督学习模型性能对比

四种模型在交叉验证与测试集上的性能对比如表 3.3 所示，对应的柱状图与 XGBoost 混淆矩阵如图 3.1 所示。




图 3.1 模型性能对比柱状图与 XGBoost 混淆矩阵

表 3.3 监督学习模型性能对比

模型	CV Accuracy	CV F1-Macro	Test	Test	Test	Test F1-Macro
			Accuracy	Precision	Recall	
LogisticRegression	0.8667±0.0365	0.8514±0.0381	0.8600	0.8556	0.8588	0.8553
DecisionTree	0.9600±0.0249	0.9552±0.0318	0.9800	0.9855	0.9778	0.9811
RandomForest	0.9467±0.0163	0.9433±0.0156	0.9600	0.9722	0.9521	0.9607
XGBoost	0.9667±0.0211	0.9648±0.0237	0.9800	0.9855	0.9778	0.9811

从表 3.3 可以看出，XGBoost 在测试集上取得了最优的综合性能，宏平均 F1 达到 0.9811，与 DecisionTree 持平，但交叉验证稳定性更优（标准差 0.0211 vs 0.0249）。XGBoost 的混淆矩阵显示（图 2 右），在 50 个测试样本中仅出现 1 例误判（1 例商旅被误判为特种兵），情侣与特种兵类别均实现 100%的精确率与召回率，说明 XGBoost 对边界样本的区分能力优于其他模型。LogisticRegression 作为线性基线，F1-Macro 仅为 0.8553，表明出行场景与特征之间存在显著的非线性关系。

3.4.2 特征重要性分析

XGBoost 与 RandomForest 的特征重要性排序分别如图 3.2 和图 3.3 所示。




图 3.2 RandomForest 特征重要性排序图




图 3.3 XGBoost 特征重要性排序图

两种模型的 Top 10 特征高度一致，但权重分配存在差异：XGBoost 更强调 member_level_num（29.17%）与 will_order_daocan（15.98%），而 RandomForest 更强调平均客单价（22.79%）。两者共同验证了消费行为与会员等级是场景识别的核心驱动力，合计贡献约 45% 的重要性。行为轨迹特征（点击、搜索、加购等）的重要性仍为 0，暴露了数据质量问题，需在后续研究中补充实时行为日志。

3.4.3 无监督学习验证结果

为验证用户行为特征在无标签条件下的自然分群能力，本研究采用 K-Means 算法进行聚类分析。首先通过肘部法则与多指标评估确定 K 值，图 3.4 展示了

K=2 至 K=7 时的轮廓系数、Calinski-Harabasz 指数与 Davies-Bouldin 指数变化曲线。综合考虑业务场景数量为 4，最终选择 K=4 进行聚类。




图 3.4 K-Means K 值评估曲线

K-Means (K=4) 的聚类评估指标如下：轮廓系数 0.1913，Calinski-Harabasz 指数 33.77，Davies-Bouldin 指数 1.8639。轮廓系数处于中等水平，说明聚类结构存在一定重叠，这与三分类任务的边界模糊性相符。Zhao 等[12]指出，在高维客户细分中，轮廓系数的绝对值受特征相关性与维度影响较大，应结合 CH 指数与 DB 指数综合判断。

聚类结果与真实标签的交叉分析如表 4 与图 3.5 和图 3.6 所示。




图 3.5 聚类分布饼图




图 3.6场景映射热力图

表 3.4 K-Means 聚类与真实场景映射

聚类	样本量	主导场景	主导占比
Cluster 0	67	商旅	73.1%
Cluster 1	85	特种兵	82.4%
Cluster 2	28	情侣	71.4%
Cluster 3	20	特种兵	70.0%
总体	200	—	76.5%

可以看出,Cluster 1 以特种兵为主导(82.4%),Cluster 0 以商旅为主导(73.1%),Cluster 2 以情侣为主导 (71.4%), 而 Cluster 3 为特种兵与情侣的混合类 (70.0% 特种兵)。总体映射准确率为 76.5%, 低于监督学习的 96.0%, 但验证了消费行为特征在无标签条件下仍具有较强的场景区分能力。对于冷启动用户 (缺乏历史标签), K-Means 聚类可作为场景识别的补充手段, 先将其归入概率最高的类簇, 再通过少量交互行为进行标签精修。

3.4.4 业务价值与策略启示

基于上述模型结果, 可为后续跨业态策略设计提供以下数据支撑:

（1）特种兵用户识别准确率最高（100%召回率），适合推送”奶茶券+共享充电宝券+经济型酒店套餐”。

（2）情侣用户以高消费金额（均值 676.89 元）与高闪购意愿（100%）为特征，应重点推荐”黑珍珠餐厅预约券+景点门票+鲜花闪购”。

（3）商旅用户会员等级高（均值 4.67），适合推送”咖啡外卖券+办公用品闪购+快速入住权益”。

（4）行为数据缺失是当前模型的主要瓶颈，建议接入入住前 1 小时的实时搜索与浏览日志，预计可将 F1-Macro 提升至 0.98 以上。

4 全链路需求预测模型

4.1 问题描述

在 3.1 节中，通过 XGBoost 多分类模型实现了出行场景的准确识别，能够有效判断用户属于商旅、情侣或特种兵中的哪一类出行场景。然而，场景识别本身并非最终业务目标，平台需要进一步回答一个更精细的问题：在不同出行场景下，用户具体会产生哪些业态的消费需求？即用户是否会点外卖、是否会到店就餐、是否会使用闪购服务。这三个问题的答案直接决定了平台应当为该用户推送什么样的优惠券组合。

从业务逻辑来看，场景识别回答的是“用户是谁”的问题，而需求预测回答的是“用户要什么”的问题。两者构成递进关系：先识别场景以圈定用户群体，再预测需求以确定权益配置。因此，全链路需求预测是连接场景识别与策略设计的中间桥梁。本研究的预测目标为以下四个二分类变量：

表 4.1 目标变量及其含义

目标变量	含义	正样本数	比例
will_order_waimai	用户是否会点外卖	180	90.00%
will_order_daocan	用户是否会到店餐饮	110	55.00%
will_order_shangou	用户是否会闪购	98	49.00%
will_order_ticket	用户是否会购买门票	0	0%

其中，“will_order_ticket”因全为 0，在后续建模中跳过。模型的输入特征来源于之前输出的用户宽表。经过严格的泄露特征排除后，最终用于建模的特征共 11 个，分为两类：

(1) 画像特征（5 个）：

- scene_label: 出行场景标签（亲子/情侣/商旅/特种兵）
- age_group: 年龄分组
- member_level_num: 会员等级数值（L1=1...L6=6）

price_level_num: 客单价分层（低=1,中=2,高=3,超高=4）

常驻城市: 用户常驻城市

(2) 行为特征 (6 个):

总行为次数: 事件行为总次数

点击次数: 点击事件次数

搜索次数: 搜索事件次数

加购次数: 加购事件次数

行为下单次数: 行为序列中的下单次数

收藏次数: 收藏事件次数

为防范数据泄露,在特征筛选中,排除了总订单数、总消费金额、外卖订单数、到餐订单数、闪购订单数、夜间订单数、平均客单价、亲子订单数等与目标变量直接相关的订单统计特征。避免模型直接通过“有订单数→有订单”的规则完美预测,导致评估指标虚高而失去实际预测价值。

4.2 模型选择

本研究选择三种代表性模型进行对比实验:

(1) 逻辑回归 (LogisticRegression)

逻辑回归是一种经典的线性分类模型,通过 Sigmoid 函数将线性组合映射到 0-1 概率空间。其优势在于模型简单、可解释性强、训练速度快,适合作为基线模型。在本研究中,逻辑回归用于评估线性模型在需求预测任务中的表现上限。为处理类别特征,所有类别变量均经过 LabelEncoder 编码后输入模型。

(2) 随机森林 (RandomForest)

随机森林是一种基于决策树的集成学习算法,通过 Bootstrap 采样构建多棵决策树,并采用投票或平均的方式输出最终结果。其优势在于:能够自动处理特征间的非线性交互关系、对异常值和缺失值鲁棒性强、可输出特征重要性,便于业务解释、不易过拟合,泛化能力较强。研究表明,随机森林在用户购买行为预测中能取得优于其他分类器的效果。在本研究中,随机森林采用 100 棵决策树, class_weight='balanced'以处理类别不平衡。

(3) XGBoost (eXtremeGradientBoosting)

XGBoost 是一种基于梯度提升框架的集成学习算法。其核心优势包括：支持自定义损失函数和评估指标、内置正则化项 (L1/L2)，有效防止过拟合、支持并行化计算，训练效率高、天然支持缺失值处理。在本研究中，XGBoost 采用 100 棵树、学习率 0.1，并通过 `scale\_pos\_weight` 参数动态调整正负样本权重以应对类别不平衡。

4.3 模型评估

在研究中，我们采用四个评估指标对模型进行全面评估：

(1) 准确率 (Accuracy)

准确率是预测正确的样本占总样本的比例。准确率直观易懂，但在正负样本不平衡时可能产生误导——如果负样本占 99%，即使模型全部预测为负类，准确率也能达到 99%。

(2) 召回率 (Recall)

召回率衡量模型找出所有正样本的能力。在需求预测场景中，召回率代表“真正有需求的用户中被模型成功识别出的比例”。高召回率意味着更少的漏报，对于追求营销覆盖率的目标尤为重要。

(3) F1 分数

F1 是精确率 (Precision) 和召回率 (Recall) 的调和平均数，在精确率和召回率之间取得平衡，适合在不平衡数据场景下综合评价模型性能。

(4) AUC (Area Under the ROC Curve)

AUC 衡量模型将正样本排在负样本之前的能力，取值范围为 0.5~1.0。AUC 越接近 1.0 表示区分能力越强。

在本研究中，AUC 被作为模型选择的主要依据。因为需求预测任务中正样本比例较低，准确率容易产生误导，而 AUC 对类别不平衡不敏感，能够更客观地反映模型的排序能力。

4.4 结果与讨论

4.4.1 模型性能对比

表 4.2 三种模型在三个预测目标上的性能表现

目标	模型	Accuracy	Recall	F1	AUC
will_order_waimai	LogisticRegression	0.575	0.583	0.712	0.625
	RandomForest	0.800	0.833	0.882	0.753
	XGBoost	0.800	0.861	0.886	0.701
will_order_daocan	LogisticRegression	0.500	0.500	0.524	0.404
	RandomForest	0.550	0.636	0.609	0.659
	XGBoost	0.700	0.818	0.750	0.846
will_order_shangou	LogisticRegression	0.475	0.500	0.488	0.520
	RandomForest	0.450	0.400	0.421	0.473
	XGBoost	0.500	0.500	0.500	0.555

外卖预测 (AUC=0.753): 随机森林表现最佳, F1 达到 0.882, 说明模型在精确率和召回率之间取得了较好的平衡。会员等级和客单价分层是贡献最大的特征, 符合业务直觉——高等级、高消费能力的用户更可能产生外卖需求。

到餐预测 (AUC=0.846): XGBoost 表现最优, 召回率达到 0.818, 说明模型能找回大部分真实到餐用户。到餐预测效果优于外卖, 可能因为到餐行为与用户画像特征的关联更为直接。

闪购预测 (AUC=0.555): XGBoost 表现最弱, AUC 仅 0.555, 接近随机猜测 (0.5)。这说明当前特征对“是否会闪购”几乎没有区分能力。可能的原因包括: 闪购需求具有较强的即时性和偶发性, 与长期画像特征关联弱、闪购品类 (如日用品、药品等) 的需求模式与餐饮类有本质差异、样例数据量小, 模型无法学习稳定的闪购需求模式。

逻辑回归表现较差: 在三个任务中, 逻辑回归的 AUC 均显著低于树模型, 到餐任务中甚至低于 0.5, 说明特征与目标变量之间存在非线性关系, 线性模型无法有效捕捉。

4. 4. 2 特征重要性分析

(1) 外卖




图 4.1 will_order_waimai（外卖）特征重要性图

从外卖预测结果来看，常驻城市是最重要的预测因子（0.32），说明不同城市的用户在出行期间的外卖消费习惯存在显著差异。一线城市（如北京、上海、深圳）的外卖基础设施成熟，用户外卖消费习惯更为普遍；而三四线城市的外卖渗透率相对较低。这一发现表明，外卖需求预测需要充分考虑城市级的地域差异。

会员等级位列第二（0.26），这与业务直觉高度吻合。高等级会员（L4-L6）在平台上具有更高的消费频率和消费意愿，在出行期间选择外卖解决用餐需求的概率也相应更高。场景标签贡献了 0.16 的重要性，说明 A 组基于规则构造的出行场景（商旅/情侣/亲子/特种兵）对外卖需求有一定区分度——商旅用户追求效率，外卖需求较高；特种兵用户追求性价比，外卖也是重要的用餐选择。客单价分层（0.11）和年龄分组（0.09）的贡献相对有限，说明这两个画像维度对外卖需求的区分能力弱于城市和会员等级。

六类行为特征（收藏次数、行为下单次数、加购次数、总行为次数、搜索次数）累计重要性不足 0.35，远低于画像特征的贡献。行为下单次数在行为特征中贡献相对较高（0.07），说明用户历史下单行为对外卖需求有一定预测价值。搜索次数贡献最低（0.04），可能原因在于外卖需求更多依赖首页推荐和店铺直接访问，搜索并非用户发现外卖的主要路径，也可能是当前数据量较小导致搜索行为的统计显著性不足。

（2）到餐




图 4.2 will_order_daocan（到餐）特征重要性图

到餐预测的特征重要性分布与外卖呈现出显著差异。场景标签占据了绝对主导地位（0.58），远超其他所有特征的总和。这说明出行场景对“是否到店就餐”具有决定性的影响。具体而言：

商旅用户：出差期间有宴请客户、同事聚餐等正式就餐需求，到餐概率最高

情侣用户：约会场景下选择西餐、日料等精致到店餐饮的意愿强

特种兵用户：追求性价比，更倾向外卖而非到店，到餐概率相对较低

这一发现具有重要的业务启示：到餐需求的营销策略应该以场景为核心进行差异化设计，而非统一推送。会员等级（0.12）和年龄分组（0.08）的贡献处于中等水平，说明用户画像对到餐需求仍有一定影响——年长用户和高等级会员更偏好到店就餐。客单价分层（0.06）和常驻城市（0.04）的贡献有限，意味着到餐需求与消费能力和地域的关联不如外卖显著。六类行为特征的累计重要性仅约 0.07，搜索次数甚至趋近于 0，几乎无贡献。这一现象可能表明：到餐决策更多依赖用户对餐厅品牌的认知和场景驱动，而非即时搜索行为。

与之前外卖的特征重要性图对比，到餐预测中场景标签的重要性（0.58）远高于外卖（0.16），表明场景是到餐需求的核心驱动因素，而外卖需求受场景影响

较小。这一差异具有业务逻辑支撑——到餐涉及外出就餐，决策受社交场景驱动；外卖是功能性用餐需求，更多受便利性驱动。

(3) 闪购




图 4.3 will_order_shangou（闪购）特征重要性图

闪购预测的特征重要性分布呈现出与外卖、到餐都不同的特点。场景标签（0.32）仍是最重要特征，但重要性低于到餐（0.58），略高于外卖（0.16）。不同场景下的闪购需求存在显著差异——商旅用户可能临时需要日用品、充电宝；亲子用户可能急需母婴用品；特种兵用户可能购买零食饮料等。

客单价分层以 0.24 的重要性跃居第二，显著高于外卖（0.11）和到餐（0.06）。这说明闪购消费具有较强的价格敏感性——低客单价用户更倾向于使用闪购购买平价日用品，而高客单价用户对闪购的依赖度较低。这一发现提示：闪购的营销策略应该针对不同消费能力用户设计差异化优惠方案。常驻城市（0.16）再次进入前三，说明不同城市用户的闪购使用习惯差异显著——一线城市即时零售基础设施完善，用户对闪购的接受度更高。会员等级（0.14）和年龄分组（0.13）贡献相当，说明这些传统画像维度对闪购有一定但有限的区分能力。

值得注意的是，闪购模型中行为特征的累计重要性显著高于其他两个目标（六类行为特征合计约 0.50，而外卖约 0.35、到餐约 0.07）。其中收藏次数（0.12）、行为下单次数（0.11）、加购次数（0.10）、搜索次数（0.08）等贡献较为均衡，说

明闪购行为是可以通过用户的历史行为信号来预测的，而非完全随机。这为改善闪购预测提供了重要线索——后续应重点补充闪购品类专属特征。

（4）总体分析

到餐需求高度依赖场景驱动，场景标签贡献了 58% 的重要性，说明到餐预测的本质是“场景识别”，模型实际上是在通过学习场景标签来预测到餐需求；外卖需求受地域和会员等级驱动，常驻城市和会员等级合计贡献 58%，说明外卖是城市基础设施和平台忠诚度共同驱动的功能性需求；闪购需求画像相对均衡，各项特征均有贡献但无绝对主导，且行为特征累计贡献最高（0.50），说明闪购是可以通过行为序列特征加以预测的，具备改善空间。常驻城市在三项目标中均有较高贡献：表明出行场景下的消费需求存在显著的地域差异，模型训练时应充分考虑城市维度。

4.4.3 数据局限性说明

本研究使用的 200 条数据，正样本比例（外卖 90%、到餐 55%、闪购 49%）远高于真实业务场景。在真实场景中，绝大多数用户不会在出行期间产生订单，正样本比例通常较低。

5 跨业态神券包设计

5.1 关联规则挖掘方法与指标体系

5.1.1 问题描述

前文已完成用户出行场景的特征识别与标签体系构建，从行程属性、行为特征等维度划分出商旅、情侣、特种兵三类核心出行用户群体，完成了用户的场景化分层与画像刻画。但场景标签仅实现了用户群体的区分，尚未深入挖掘不同场景与用户消费品类偏好之间的量化关联，也未形成可直接落地的场景化营销方案，场景标签的业务价值尚未充分释放。

基于此，本章以用户出行场景标签为基础，结合全量订单的二级品类消费数据，通过 Apriori 算法挖掘不同出行场景与消费品类的关联规律；同时补充各场景下的品类消费渗透率分析，全面刻画不同场景用户的消费结构；最终基于两类分析结果，定制差异化的跨业态动态神券包方案，实现营销权益与用户需求的精准匹配。

5.1.2 关联规则挖掘

（1）算法选择与原理

跨业态推荐场景下，关联规则挖掘可从海量用户行为数据中识别消费偏好与品类关联规律，规避纯经验策略的主观性偏差。本研究选用经典 Apriori 算法，该算法原理透明、可解释性强，已在零售促销组合、电商个性化推荐等场景被广泛验证有效；其逐层迭代挖掘频繁项集的机制可输出清晰的量化规则指标，适配策略落地与业务解释需求。

算法核心逻辑为：先筛选满足最低支持度的全部频繁项集，再基于频繁项集生成符合要求的关联规则。结合业务目标，本研究将出行场景标签与消费品类统一纳入项集元素，挖掘“特定出行场景→特定消费品类”的单向关联规则，为券包方案设计提供量化依据。

（2）核心评价指标

本研究采用支持度、置信度、提升度三个核心指标衡量关联规则的价值，各指标定义如下：

① 支持度 (Support):

$$\text{计算公式: } Support(A \rightarrow B) = \frac{\text{同时包含场景 } A \text{ 和品类 } B \text{ 的用户数}}{\text{总用户数}}$$

业务含义：反映场景 - 品类组合在全体用户中的覆盖广度，支持度越高说明该组合的普适性越强，面向全量用户投放的价值越高。

② 置信度 (Confidence):

$$\text{计算公式: } Confidence(A \rightarrow B) = \frac{\text{同时包含场景 } A \text{ 和品类 } B \text{ 的用户数}}{\text{属于场景 } A \text{ 的总用户数}}$$

业务含义：反映在给定用户属于某一场景的条件下，该用户消费对应品类的概率，体现场景对品类消费的带动能力。置信度越高，说明该场景下用户消费该品类的意愿越强。

③ 提升度 (Lift):

$$\text{计算公式: } Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{\text{品类 } B \text{ 在全量用户中的消费占比}}$$

业务含义：提升度是衡量场景与品类关联强度的核心指标，它剔除了品类本身的流行度干扰，纯净反映场景对品类消费的额外提升作用。当提升度 > 1 时，说明该场景对品类消费存在正向促进作用；提升度数值越大，场景与品类的关联强度越强，该品类对该场景用户的专属属性越突出。

5.1.3 阈值设定依据与参数校准

关联规则的输出质量高度依赖阈值的合理设定：阈值过高易过滤掉具备场景辨识度的特色消费规律，丢失差异化营销依据；阈值过低则会引入大量偶发冗余规则，干扰核心结论提取。本次研究结合数据集样本规模、二级品类分布特征与本地生活营销落地需求，遵循“统计可行 + 业务有效”的原则，经多轮预实验迭代校准，最终确定三项指标阈值如下：

(1) 最小支持度阈值：0.05

支持度用于锁定具备规模化营销价值的品类，过滤受众极窄的长尾组合。若阈值升至 0.08 及以上，仅快餐简餐、饮品等全民级品类能够入选，无法体现场

景消费偏好差异；若阈值降至 0.02 及以下，则会生成上百条偶发消费规则，不具备批量投放的用户规模。

结合国内同类研究 0.03~0.08 的常用阈值区间，最终选定 0.05：既保证入选组合覆盖至少 5% 的全量用户，具备规模化投放基础；又能完整保留丽人、果切、超市卖场等场景特色品类，充分捕捉三类场景的消费结构差异。

（2）最小置信度阈值：0.2

置信度用于保障规则的预测参考价值，排除极低概率的偶然关联。若阈值设为 0.4 及以上，仅剩余极少数通用餐饮品类，完全失去场景差异化挖掘意义；若阈值设为 0.1 及以下，则无法区分随机消费与场景驱动的倾向性消费。

经全量样本测算，二级品类在单场景下的平均消费占比约为 0.15。将阈值设为 0.2 略高于整体平均水平，可确保所有入选规则均体现出场景对品类消费的正向带动作用，而非用户随机消费行为。

（3）最小提升度阈值：1.1

提升度用于剔除品类自身流行度干扰，纯净衡量场景带来的额外消费增益，理论上提升度 >1 才代表场景对消费存在正向驱动。若仅以提升度 >1 为标准，会纳入大量弱正向关联的通用品类，无法凸显场景专属消费特征；若阈值升至 1.5 及以上，则会丢失大量高频刚需品类，导致后续券包权益覆盖不足、受众过窄。

最终选定 1.1 作为阈值：既严格排除无关联与负向关联的无效规则，又保留了从弱正向到强正向的全梯度有效规则，可同时筛选出高提升度的场景特色品类与高覆盖的通用刚需品类，完美匹配跨业态神券包的多层级权益设计需求。

5.2 品类关联规则结果分析

通过 Apriori 算法对样本用户的场景与品类数据进行挖掘，在上述设定的阈值条件下共筛选出有效关联规则，按提升度（关联强度）降序排列的前 12 条规则如表 5-1 所示。

表 5-1 各场景品类关联规则表

出行场景	消费品类	支持度	置信度	提升度
商旅	咖啡	0.0761	0.2500	2.1413
情侣	小吃快餐	0.0659	0.2600	1.8293
情侣	美甲	0.0558	0.2200	1.8058
情侣	美发	0.0507	0.2000	1.7130
商旅	中式正餐	0.1776	0.5833	1.5322
情侣	奶茶	0.0609	0.2400	1.4775
情侣	大型超市/卖场	0.0508	0.2000	1.4593
商旅	大型超市/卖场	0.0609	0.2000	1.4593
情侣	小型超市	0.0761	0.3000	1.4415
情侣	饮品	0.1015	0.4000	1.4071
商旅	健身中心	0.0964	0.3167	1.3862
商旅	奶茶	0.0558	0.1833	1.1286
商旅	快餐简餐	0.2538	0.8333	1.1092
特种兵	健身中心	0.1117	0.2529	1.1070
情侣	中式正餐	0.1066	0.4200	1.1032

结合表 5-1 的结果，可得到以下分析结论：

（1）三类出行场景均存在提升度显著高于 1 的品类规则，验证了出行场景对用户消费品类偏好具有显著的区分作用，基于场景标签进行品类权益匹配具备扎实的数据支撑。

（2）从关联强度（提升度）来看，特种兵场景与小吃快餐、情侣场景与美

甲、商旅场景与咖啡的提升度位列对应场景首位，是各场景下关联强度最高的品类组合。这类品类与场景的绑定性极强，是场景用户的特色消费需求，也是券包中差异化权益的核心来源。

（3）从置信度来看，快餐简餐、饮品等通用餐饮品类在三类场景中均保持较高置信度，说明这类品类是各场景用户的共性基础需求，适合作为普适性权益纳入券包。

（4）从支持度来看，快餐简餐、中式正餐等品类的支持度整体更高，说明这类场景 - 品类组合的用户覆盖范围更广，投放后可触达更多用户。

5.3 各场景品类消费渗透率分析

关联规则挖掘侧重识别场景与品类的强关联特色需求，但无法完整体现各场景用户的整体消费结构。为了保障券包权益的覆盖广度，本研究补充计算各场景下的品类消费渗透率，刻画用户的高频消费盘，作为券包设计的兜底依据。

5.3.1 渗透率定义

某品类在对应场景的渗透率 =
$$\frac{\text{该场景下消费该品类的订单数量}}{\text{该场景的全部订单数量}}$$

渗透率数值越高，说明该品类在对应场景中的消费越普遍，是用户的高频刚需品类。

5.3.2 渗透率结果分析

各场景下渗透率排名前 5 的消费品类结果如表 5-2 所示。

表 5-2 各场景 TOP5 品类消费渗透率

出行场景	排名	消费品类	渗透率
商旅	1	快餐简餐	34.32%
商旅	2	中式正餐	10.65%
商旅	3	健身中心	6.51%
商旅	4	饮品	5.33%
商旅	5	咖啡	5.03%
情侣	1	快餐简餐	24.92%
情侣	2	中式正餐	10.36%
情侣	3	饮品	7.77%
情侣	4	小型超市	5.83%
情侣	5	奶茶	4.21%
特种兵	1	快餐简餐	31.02%
特种兵	2	健身中心	7.92%
特种兵	2	饮品	7.92%
特种兵	4	中式正餐	6.60%
特种兵	5	小型超市	5.94%

从表 5-2 渗透率结果可以看出三类场景用户的消费结构存在显著差异：

（1）商旅场景：用户消费高度集中于便捷型餐饮，快餐简餐、咖啡渗透率位居前两位，符合商旅用户时间成本高、追求高效用餐的行为特征；正餐与超市品类紧随其后，分别满足商务宴请与旅途补给需求。

（2）情侣场景：用户消费偏向社交体验型品类，中式正餐、奶茶、火锅等适合双人共享的餐饮品类渗透率领先，美甲等丽人品类也进入前五，体现了情侣出行以休闲、约会为核心的消费属性。

（3）特种兵场景：用户消费以平价、便捷的品类为主，小吃快餐、快餐简餐、饮品等高频刚需品类渗透率最高，超市、果切等即时补给类品类占比突出，匹配特种兵式旅游行程紧凑、注重性价比与即时补给的消费特点。

渗透率分析的核心价值在于锁定各场景用户的“基本盘”消费品类，将这类品类纳入券包可以保证绝大多数场景用户都能找到可使用的权益，避免券包因过度侧重小众强关联品类而出现受众过窄、核销率低的问题。

5.4 跨业态动态神券包方案设计

5.4.1 方案设计思路

结合关联规则挖掘与渗透率分析的结果，本次神券包采用“1+3+1”的跨业态权益结构，即 1 项基础住宿权益 + 3 项核心消费权益 + 1 项场景特色权益，具体筛选逻辑如下：

（1）基础住宿权益：统一配置酒店住宿立减券，作为所有出行场景的通用核心权益，覆盖用户出行的核心刚性需求。

（2）核心消费权益：采用“强关联优先、高频兜底”的筛选原则：优先选取该场景下提升度排名前 2 的强关联品类，匹配用户的场景特色消费偏好，提升权益的精准吸引力；再从高渗透率品类中补充 1 个未重复的高频品类，保障权益的覆盖广度，最终形成 3 个跨业态的核心消费品类权益。

（3）场景特色权益：针对三类场景的差异化出行痛点，配置专属特色权益，强化券包的场景专属感，提升用户的感知价值。

5.4.2 最终方案推荐

按照上述设计逻辑，最终生成三类出行场景的专属跨业态神券包，完整方案如表 5-3 所示。

表 5-3 场景专属神券包方案表

出行场景	券包名称	优惠券组合	设计依据
商旅	商旅专属跨	酒店住宿立减券 + 咖啡饮品立减券 + 正餐	强关联品类：咖啡 (提升度 2.14)、中式正餐 (提升度 1.53)；覆盖高频消费：快餐简餐、中式正餐；匹配商旅用户商务出行、高效便捷的核心行为特征。
	业态神券包	满减券 + 快餐通用券 + 打车出行抵扣券	
情侣	情侣专属跨	酒店住宿立减券 + 小吃快餐	强关联品类：小吃快餐 (提升度 1.83)、美甲 (提升度 1.81)；覆盖高频消费：快餐简餐、中式正餐；匹配情侣约会场景
	业态神券包	吃美食券 + 美甲服务券 + 快餐通用券 + 鲜花礼品券	下餐饮 + 丽人的复合消费需求。
特种兵	特种兵专属跨业态神券包	酒店住宿立减券 + 健身体验券 + 快餐通用券 + 饮品通用券 + 共享充电宝权益券	强关联品类：健身中心 (提升度 1.11)；覆盖高频消费：快餐简餐、饮品；匹配特种兵穷游、高性价比的消费特征。

5.4.3 方案应用价值

本次设计的跨业态神券包基于真实消费数据挖掘生成，相较于传统的通用券包具有两方面优势：

一方面，权益匹配更精准。通过提升度指标锁定场景强关联品类，让券包权益贴合用户的场景化消费偏好，能够有效提升用户的领券意愿与核销转化率。

另一方面，权益结构更合理。结合强关联特色品类与高渗透率通用品类，兼顾了权益的精准性与覆盖广度，既能够打造差异化的场景专属权益，又能够保障大多数场景用户的使用需求，实现营销资源效率的最大化。

5.5 结果可视化

(1) 场景 - 品类关联提升度热力图




图 5-1 出行场景与核心消费品类关联提升度热力图

如图 5-1 所示，提升度热力图以颜色深浅映射关联强度，直观呈现商旅与咖啡、情侣与小吃快餐及美甲的强差异化关联，是筛选高提升度核心品类的核心依据。

（2）各场景品类渗透率分布




图 5-2 各场景 Top5 品类渗透率分布

如图 5-2 所示，各场景 Top5 品类渗透率条形图展示了不同场景的高频消费结构，快餐简餐为三类场景共同刚需，中式正餐在商旅场景占比突出，为“高渗透率兜底”的设计原则提供数据支撑。

（3）神券包权益维度雷达图




图 5-3 神券包权益维度雷达图

如图 5-3 所示，神券包权益维度雷达图从五个维度对比三类券包的权益分布，清晰体现商旅重出行、情侣重休闲、特种兵重刚需的差异化定位，直观呈现场景化动态组合的设计效果。

为进一步展示所有规则的分布特征，本研究绘制了支持度 - 提升度散点图，以点的大小代表置信度高低。从图中可以看出，商旅 - 咖啡规则呈现“中支持度、高提升度”的特征，是最具差异化价值的规则；快餐简餐类规则呈现“高支持度、低提升度”的特征，属于普适性刚需品类。该图能够直观体现三个评价指标的权衡关系，验证了“提升度优先 + 渗透率兜底”筛选机制的合理性。




图 5-4 关联规则多指标散点图

5.6 结果分析与业务讨论

5.6.1 关联规则结果解读

从挖掘结果来看，三类出行场景的消费偏好呈现出明显的差异化特征，与业务认知高度一致，验证了关联规则挖掘的有效性：

（1）商旅场景：呈现“商务刚需为主、特色需求突出”的特征。中式正餐、快餐简餐等高渗透率品类保障了基础饮食需求，而咖啡品类的高提升度则精准命中了商旅用户提神醒脑、商务会谈的差异化痛点，是该场景券包的核心差异化权益。

（2）情侣场景：呈现“餐饮 + 丽人”的约会消费特征。小吃快餐、美甲、美发等品类提升度均较高，说明情侣出行更偏向休闲体验类消费，券包设计也围绕约会全链路展开，覆盖了从餐饮到形象管理的需求。

（3）特种兵场景：呈现“大众化、高性价比”的特征。整体提升度偏低，说明该场景用户消费更偏向全民刚需品类，没有特别显著的专属偏好，因此券包设计以高频平价权益为主，辅以共享充电宝等痛点权益，主打实用性。

5.6.2 策略业务可行性分析

本研究设计的跨业态神券包具有较强的业务落地价值：

（1）所有权益均基于真实用户消费数据挖掘生成，而非主观臆断，能够保证券包的用户接受度与核销潜力；

（2）“酒店 + X”的结构能够有效打通住宿与本地生活业态，带动平台非住宿业务的营收增长，实现交叉销售的业务目标；

（3）差异化的场景化设计能够提升用户对平台的感知价值，增强用户粘性，相比统一发券的模式更具精细化运营优势。

5.6.3 策略局限性分析

受限于数据样本规模，本策略仍存在一定局限性：一是样本量仅 200 人，部分小众品类的规则统计显著性有待进一步验证；二是仅基于单天的订单数据进行挖掘，未考虑时间维度的消费波动；三是券包仅设计了品类组合，未涉及具体面额、门槛等精细化参数，落地时需结合营销预算进一步校准。

6 总结与展望

6.1 研究总结

本研究围绕“出行场景下用户全链路动线分析与跨业态智能推荐”这一核心问题，基于美团用户画像表（200 条）与交易订单表（约 1000 条），构建了从数据融合、场景识别、需求预测、策略推荐的完整分析链路，形成了以下主要结论：

（1）订单行为与画像特征的融合能够有效识别用户出行场景：

本研究首先通过 `user_id` 关联两表，提取了 8 个订单聚合特征与 4 个画像衍生特征，采用业务规则构造了商旅、情侣、亲子、特种兵四类场景标签。在此基础上，构建了 XGBoost 多分类模型，针对亲子样本仅 1 例的极端不平衡问题实施“亲子并入情侣”的合并策略，模型在测试集上达到 98.0% 的准确率与 0.9811 的 F1。

特征重要性分析表明，`member_level_num`（会员等级）与平均客单价是场景识别的核心驱动力，合计贡献约 45% 的重要性。K-Means 无监督聚类进一步验证了消费行为特征在无标签条件下的场景区分能力，总体映射准确率为 76.5%。这一结论验证了基于订单行为数据识别出行人群类型的可行性。

（2）不同业态的需求驱动因素存在显著差异，需分别建模：

分别针对外卖、到餐、闪购三个业态构建了二分类预测模型，通过排除订单统计类泄露特征确保预测的因果有效性。实验结果表明：到餐预测效果最优（ $AUC=0.846$, XGBoost），场景标签贡献了 58% 的特征重要性，说明到餐需求高度依赖场景驱动，商旅用户因商务宴请需求到餐概率最高，情侣用户因约会场景选择精致餐饮的意愿强；外卖预测效果中等（ $AUC=0.753$, RandomForest），常驻城市与会员等级合计贡献 58%，说明外卖是城市基础设施与平台忠诚度共同驱动的功能性需求；闪购预测效果较弱（ $AUC=0.555$ ），行为特征累计贡献约 50%，说明闪购可通过行为序列加以预测但需补充品类专属特征。

（3）关联规则挖掘能够有效识别场景差异化消费偏好：

采用 Apriori 算法挖掘场景与品类的关联规则，以支持度、置信度、提升度为核心评价指标。结果表明：商旅场景与咖啡的关联强度最高（提升度 2.14），情侣场景与小吃快餐（提升度 1.83）、美甲（提升度 1.81）关联显著，特种兵场

景整体提升度偏低、消费更偏向大众化刚需品类。三类场景的消费偏好呈现出明显的差异化特征，与业务背景中“商旅用户追求效率与咖啡/快餐”“情侣用户关注氛围感餐厅”“特种兵用户追求高性价比”的描述高度吻合，验证了关联规则挖掘在出行场景消费偏好识别中的有效性。

（4）“提升度优先+渗透率兜底”的三层筛选机制能够有效兼顾精准性与覆盖率：

基于关联规则挖掘结果，构建了“高提升度优先+高渗透率兜底+场景特色补充”的三层筛选逻辑，生成了三类场景的专属跨业态神券包方案。商旅券包以咖啡（提升度 2.14）和中式正餐（提升度 1.53）为核心差异化权益，匹配商旅用户高效便捷的商务出行特征；情侣券包以小吃快餐（提升度 1.83）和美甲（提升度 1.81）为核心权益，覆盖约会场景下“餐饮+丽人”的复合消费需求；特种兵券包以健身中心（提升度 1.11）为特色权益，辅以快餐简餐和饮品等高频刚需品类，匹配特种兵用户高性价比的消费特征。该方案通过热力图、雷达图、散点图等多形式可视化呈现，验证了“酒店+X”场景化推荐模型在跨业态动态组合策略中的可行性。

总体而言，本研究验证了基于订单行为与画像特征融合的方法能够有效识别用户出行场景并预测其衍生需求，为平台跨业态精准营销提供了可落地的数据驱动方案，构建了“识别、预测、推荐”的分析链路。

6.2 业务价值讨论

（1）支撑精细化场景营销：出行场景识别模型能够以 98% 的准确率将用户自动归入商旅、情侣、特种兵三类场景，使平台无需依赖用户主动填写即可实现大规模自动化场景打标。这一能力可支撑平台在用户入住前完成场景预判，从而在“规、订、游、结”全链路中实施差异化的营销触达策略。

（2）指导差异化权益配置：通过关联规则挖掘结果揭示了不同场景用户的品类偏好差异，为券包设计提供了量化依据。平台可根据场景标签动态配置权益组合：商旅用户重点推送咖啡与正餐权益，情侣用户重点推送休闲餐饮与丽人权益，特种兵用户重点推送高性价比刚需权益。这种基于数据的精细化配置相比传统统一发券模式，能够有效提升券包的核销率与销售转化率。

（3）验证跨业态协同的可能性：设计的“酒店+X”神券包方案以酒店住宿为核心锚点，向外卖、到餐、闪购、丽人等业态辐射，验证了以“出行”为串联线索实现跨业态协同增长的技术可行性。这一思路可进一步推广至更多本地生活

场景，为平台级跨业态组合策略提供方法论参考。

6.3 研究展望

本次研究围绕出行场景下的用户识别、需求预测与跨业态券包设计构建了完整分析链路，验证了场景化标签在本地生活精准营销中的应用价值。但受样本规模、数据维度与研究边界的约束，研究结论与策略方案仍存在多方面的拓展与深化空间。结合分析过程中暴露的问题与业务落地的实际需求，后续可从数据、算法、策略、落地四个维度展开进一步探索。

（1）数据维度的拓展与体系完善

数据质量是模型精度与策略有效性的基础约束。当前研究仅基于 200 名用户的单日交易数据展开，样本规模有限且以横截面特征为主，行为类特征存在不同程度的缺失，限制了结论的普适性与模型的上限。后续可从三个层面完善数据体系：

从样本覆盖来看，可扩充不同城市层级、不同出行时段的用户样本，重点补充亲子等小众场景的样本量，缓解类别不平衡问题，降低小样本带来的结论偏差，提升模型与关联规则的泛化能力。

从时空特征来看，可将单期横截面数据拓展至多周期纵向数据，覆盖工作日、节假日与旅游淡旺季，捕捉不同时间节点下用户消费行为的波动规律；同时补充用户地理位置、酒店区位、行程阶段等时空属性，为分时段、分场景的精准权益推送提供支撑。

从特征丰富度来看，可补全用户全链路行为数据。本次研究中点击、搜索、加购等行为轨迹特征的缺失，直接制约了闪购等业态的需求预测效果。后续接入从浏览、搜索到下单的全路径行为日志后，能够补充实时行为信号，进一步提升需求预测的准确性与场景识别的时效性。

（2）模型方法的深化与性能优化

研究已验证 XGBoost、随机森林等集成模型在场景识别与需求预测任务中的有效性，但现有模型仍存在依赖人工规则、弱需求场景预测能力不足等局限，可从精度与适用性两方面持续优化。

在场景分群机制上，当前标签依赖业务规则构造，监督学习本质是对既有规则的拟合。后续可引入半监督学习与无监督聚类相结合的分群框架，降低对人工规则的依赖，挖掘数据中自然形成的用户分群模式，识别更多潜在的细分出行场

景。

在弱需求预测上，针对闪购等当前预测效果接近随机的业态，可补充品类级细粒度特征与用户历史行为序列，尝试引入时序模型、图神经网络等方法捕捉即时消费的内在规律；同时探索多任务学习框架，借助外卖、到餐等易预测任务的信息辅助闪购任务学习，实现多业态需求预测的协同提升。

在关联规则挖掘上，当前仅实现了场景与品类的共现关联挖掘，后续可引入序列模式挖掘算法，识别用户出行全链路中的消费顺序与转化路径；同时加入消费金额、复购频次等业务权重，挖掘高价值导向的关联规则，使规则筛选更贴合平台的实际营收目标。

（3）营销策略的精细化与动态化

本次研究仅完成了场景专属券包的品类组合设计，距离可直接落地的精细化运营方案仍有差距。后续可围绕权益参数、推送时机与个性化粒度三个维度，推进策略的细化与迭代。

在权益参数层面，可结合不同场景用户的客单价分布与价格敏感度，设定差异化的优惠券面额、满减门槛与有效期，避免“一刀切”的权益设置；同时设计不同面额的梯度组合，匹配不同消费能力的用户群体，进一步提升核销转化率。在推送时机层面，可打破当前静态券包的固定模式，结合用户出行“规划 - 预订 - 入住 - 在途 - 离店”的全生命周期阶段，动态调整权益组合。例如预订阶段推送酒店与正餐的组合权益，入住当日推送咖啡、闪购等即时需求权益，离店前推送伴手礼、特产类权益，实现全链路的精准触达。

在个性化粒度层面，可在场景分层的基础上，进一步结合用户年龄、会员等级、历史消费偏好等画像特征，实现“场景 + 个体”的双维度个性化推荐，从当前三类场景的标准化券包，升级为更贴合个体需求的动态权益组合，提升营销精准度。

（4）落地闭环的构建与迭代机制

当前研究仍处于离线分析阶段，策略效果仅通过数据逻辑推导，尚未经过真实业务场景的检验。后续可逐步构建从部署、验证到迭代的全链路落地闭环，推动研究成果向实际应用转化。

首先是推进模型与策略的工程化部署。将场景识别模型、需求预测模型与关联规则库接入实时推荐系统，实现用户场景的实时判定、需求的动态预估与券包的自动发放，完成从离线分析到在线应用的转化。

其次是通过 A/B 测试实现效果量化评估。设置对照组与实验组，对比场景化专属券包与通用券包在核销率、客单价、交叉消费转化率、用户留存率等核心指标上的差异，量化研究方案的实际业务价值，验证策略的真实有效性。

最后是建立数据回流的长效迭代机制。基于真实投放数据持续回流，定期更新模型参数、调整规则阈值与券包结构，形成 “数据输入 - 模型输出 - 策略投放 - 效果反馈 - 模型迭代” 的正向循环，使策略持续适配用户需求变化与平台业务发展。

7 分工协作说明

本项目从数据工程、模型构建到报告撰写，由杨玥萌、史俊杰、高琪、益西措姆四位同学分工协作完成。

7.1 项目执行阶段

(1) 数据预处理与特征工程（杨玥萌）

基于用户画像表（200 条）与交易订单表（约 1000 条），通过 `user_id` 进行关联，提取了 8 个订单聚合特征（总订单数、总消费金额、外卖/到餐/闪购订单数、夜间订单数、平均客单价、亲子订单数）与 4 个画像衍生特征（年龄分组、会员等级数值化、客单价分层数值化、常驻城市），构造了商旅、情侣、亲子、特种兵四类出行场景标签，最终输出清洗后的用户宽表 `cleaned_data.csv`（200 个用户 × 18 列特征）及特征说明文档 `feature_description.xlsx`。

(2) 出行目的识别模型（史俊杰）

以 XGBoost 与随机森林为核心模型，以逻辑回归与决策树为基线模型，开展多分类任务。针对亲子样本仅 1 例的极端不平衡问题，采用合并策略（亲子并入情侣），形成商旅、情侣、特种兵三分类任务。通过 5 折分层交叉验证与 8:2 训练测试划分评估模型性能，输出每个用户的场景预测标签及概率分布、特征重要性排序。同时采用 K-Means 聚类（K=4）进行无监督验证，利用轮廓系数、Calinski-Harabasz 指数与 Davies-Bouldin 指数评估聚类质量，并将聚类结果与真实场景标签进行交叉验证。

(3) 全链路需求预测模型（高琪）

分别针对外卖（`will_order_waimai`）、到餐（`will_order_daocan`）、闪购（`will_order_shangou`）三个二分类预测任务，采用逻辑回归、随机森林、XGBoost 三种模型进行训练和对比。以 AUC 为主要评估指标，结合准确率、召回率、F1 分数进行综合评价，识别对各类需求预测贡献最大的特征，输出每个用户对三类需求的发生概率。

(4) 跨业态神券包设计（益西措姆）

采用 Apriori 关联规则挖掘算法，对用户场景标签与跨品类消费数据进行联合挖掘，以支持度、置信度、提升度为核心评价指标，识别不同出行场景下的差异化消费偏好与品类关联规律。基于挖掘结果构建“提升度优先+渗透率兜底+场景特色补充”的三层筛选逻辑，生成差异化的场景专属券包方案，并通过热力图、雷达图、散点图等可视化形式对策略结果进行呈现。

7.2 报告撰写阶段

（1）第 1 章绪论整合与第 2 章撰写（杨玥萌）

完成第 1 章绪论的全文整合——将各部撰写的 1.1（研究背景与意义）、1.2（国内外研究现状）、1.3（研究内容）、1.4（研究思路与技术路线）内容进行有机融合，形成完整的一章；同时撰写第 2 章数据采集与预处理（2.1-2.3），并将四人各自绘制的局部技术路线图合并为一张完整的总体技术路线图（图 1.1）。

（2）第 3 章出行目的识别模型（史俊杰）

撰写第 3 章出行目的识别模型（3.1-3.4），涵盖问题描述、模型选择、实验设计、结果与讨论等内容。

（3）第 4 章全链路需求预测模型（高琪）

撰写第 4 章全链路需求预测模型（4.1-4.4），涵盖问题描述、模型选择、模型评估、结果与讨论等内容。

（4）第 5 章跨业态神券包设计与第 6 章总结展望（益西措姆）

撰写第 5 章跨业态神券包设计（5.1-5.6），系统论述关联规则挖掘方法与指标体系、品类关联规则结果分析、各场景品类消费渗透率分析、跨业态动态神券包方案设计及可视化呈现；同时撰写第 6 章总结与展望（6.1-6.3），对研究结论、业务价值及未来改进方向进行系统梳理。

（5）全文统稿与文献整理（杨玥萌）

杨玥萌同学承担了摘要撰写、全文格式统稿、目录生成、插图清单与表格清单的整理工作。全体参考文献由杨玥萌同学统一收集、去重、重新编号（共计 36 篇），并按正文引用顺序排列，确保所有文献符合 GB/T 7714 标准格式，正文引用与文献列表一一对应，最终形成完整报告终稿。

参考文献

- [1] 胡宝雨,刘学.基于手机信令数据的城市区域居民出行 OD 预测模型[J].交通运输系统工程与信息,2023,23(6):296-306.
- [2] Gomes M A, Meisen T. A review on customer segmentation methods for personalized customer targeting in e- commerce use cases[J]. Information Systems and e-Business Management, 2023, 21(3): 527-570.
- [3] 郝爽,李国良,冯建华,等.结构化数据清洗技术综述[J].清华大学学报(自然科学版),2018,58(12):1037-1050.
- [4] Guyon I, Elisseeff A. An introduction to variable and feature selection[J]. Journal of Machine Learning Research, 2003, 3(Mar): 1157-1182.
- [5] Zhang B, Wang L, Li Y. Precision marketing method of e- commerce platform based on clustering algorithm[J]. Complexity, 2021, 2021(1): 5538677.
- [6] 王梦晓.基于外卖数据的热点区域挖掘及订单量预测[D].浙江大学,2022.
- [7] 肖云, 刘洋, 陈曦. 基于改进 K 近邻算法的城市配送需求量预测[J]. 运筹与管理, 2023, 32(11): 88-94.
- [8] 丁翔, 倪丽萍, 韩露. 基于深度学习的即时配送时间预测模型[J]. 计算机集成制造系统, 2024, 30(2): 612-622.
- [9] 唐茜. 基于教育数据挖掘的学生画像构建与学情预测分析研究[J]. 现代教育技术, 2023, 33(4): 89-96.
- [10] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016: 785-794.
- [11] Ni Y, Duan J. Intelligent classification method for e- commerce customers based on improved XGBoost model[J]. Journal of Computational Methods in Sciences and Engineering, 2025, 25(1): 115-128.
- [12] Xie J. An accurate identification method of abnormal users in social network based on multivariate characteristics[J]. International Journal of Web Based Communities, 2023, 19(2/3): 80-92.
- [13] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [14] Zhao H H, Luo X C, Ma R, et al. An extended regularized K- means clustering approach for high- dimensional customer segmentation with correlated variables[J]. IEEE Access, 2021, 9: 48405-48412.
- [15] 周开乐,杨善林,丁帅,等.聚类有效性研究综述[J].系统工程理论与实践,2014,34(9):2417-2431.

- [16] Ikotun A M, Habyarimana F, Ezugwu A E. Cluster validity indices for automatic clustering: A comprehensive review[J]. Heliyon, 2025, 11(2): e41953.
- [17] Latief M, Bhat S. Attention- driven graph neural network for spatial- temporal demand prediction in food delivery[J]. Expert Systems with Applications, 2025, 264: 125876.
- [18] Zhao Y, Wang X, Li H, et al. STKDRec: Spatial- temporal knowledge distillation for takeaway recommendation[J]. Information Sciences, 2024, 678: 121023.
- [19] Deng L, Wang Y, Chen Z, et al. Context- driven recommendation via heterogeneous temporal modeling and large language model in the takeout system[J]. Applied Sciences, 2025, 15(8): 4321.
- [20] Sarkar A, Jana B, Paria A, et al. Radical analysis review on improved versions of Apriori algorithm for association rule mining[J]. Turkish Journal of Computer and Mathematics Education, 2022, 11(1): 476-482.
- [21] Guo Y. Application of improved Apriori algorithm in mobile e-commerce recommendation system[J]. Industrial Management & Data Systems, 2017, 117(2): 287-303.
- [22] Chen A H-L, Gunawan S. Enhancing retail transactions: A data-driven recommendation using modified RFM analysis and association rules mining[J]. Applied Sciences, 2023, 13(18): 10057.
- [23] 郭允涛, 白钊. 基于改进 K-means 算法的航空客户细分研究[J]. 计算机工程与应用, 2023, 59(1): 276-283.
- [24] 张敏, 王磊. 基于 RFM 的聚类算法在零售市场客户细分中的应用比较[J]. 统计与决策, 2024, 40(10): 88-93.
- [25] 王丽娟, 李志鹏, 陈亮. 基于改进的 K-means 和 BP-Adaboost 的寿险客户流失预测算法[J]. 山东科技大学学报 (自然科学版), 2022, 41(1): 54- 65.
- [26] 陆振波, 冯泽禹, 张改, 等. 一种基于手机信令数据的出行目的识别方法[P]. 中国专利: CN202110896262.7, 2021-12-28.
- [27] 胡宝雨, 刘学. 基于手机信令数据的城市区域居民出行 OD 预测模型[J]. 交通运输系统工程与信息, 2023, 23(6): 102-112.
- [28] Vlahogianni E, Mourtakos V, Mantouka E, et al. Reconstructing mobility from smartphone data: Empirical evidence of the effects of COVID-19 pandemic crisis on working and leisure[J]. Travel Behaviour and Society, 2023, 33: 100608.
- [29] 丁翔, 倪丽萍, 韩露. 基于深度学习的即时配送时间预测模型[J]. 合肥工业大学学报 (自然科学版), 2024, 47(9): 1201-1209.

- [30] 肖云, 刘洋, 陈曦. 基于改进 K 近邻算法的城市配送需求量预测[J]. 运筹与管理, 2023, 32(11): 88-94.
- [31] 史达, 于淼川, 李梦琪. 基于用户隐式数据的个性化酒店推荐算法[J]. 山东大学学报 (理学版), 2021, 56(7): 1-10.
- [32] 林穗, 刘伟, 张华. 改进 Apriori 算法在电商个性化推荐中的应用[J]. 计算机应用研究, 2024, 41(3): 812-818.
- [33] 王君威, 赵楠, 郑宇. 关联规则与协同过滤融合的推荐算法研究[J]. 小型微型计算机系统, 2023, 44(6): 1265-1272.
- [34] 朱龙. 带利润权重的 Apriori 改进算法及在零售促销中的应用[J]. 系统工程理论与实践, 2024, 44(7): 2205-2216.
- [35] 孙一凡, 何明, 周丽. 基于改进 Apriori 算法的促销产品组合优化[J]. 管理科学, 2025, 38(2): 112-125.
- [36] 刘巧, 李华, 孙丽. 基于 RFM 聚类与关联规则的社交电商用户分层研究[J]. 数据分析与知识发现, 2024, 8(5): 76-86.